

Spectral-Parameter Learning for Lax Connections

研究ノート

2026 年 9 月 13 日

1 目的

本ノートは、既発表論文

O. Fukushima, T. Shigemura, R. Suda, N. Tanahashi and K. Yoshida, “Machine-Learning Search for Lax Connections,” [arXiv:2608.05146](https://arxiv.org/abs/2608.05146)

の後続研究として、スペクトルパラメータを含む Lax connection の機械学習を整理するための作業ノートである。共同研究者から共有された二つの計算ノートに含まれる取り組みを整理し、既発表論文との差分を区別したうえで、再現計算と追加検証を記録する。

各節は、前の節を読まなくても計算設定を復元できることを目標とする。研究グループ内だけで通用する分類名や記号は用いず、場, current, 方程式, 残差, 学習対象, 損失関数, 評価量を初出時に定義する。

2 共同研究者ノートに含まれる六つの取り組み

比較対象は次の二つである。

1. N. Tanahashi, “Explicit Spectral-Parameter Learning in the PCM: Implementation Notes and Numerical Results,” May 24, 2026.
2. N. Tanahashi, “Machine-Learning the Spectral Parameter for the S^2 Coset: Prior-Free Discovery, Tracing, and Charting of the Lax Family,” June 9, 2026.

第一のノートは $SU(2)$ principal chiral model に対する三種類の損失構成を比較する。第二のノートは $S^2 = SU(2)/U(1)$ sigma model に対して、flatness solution set の局所構造の同定, continuation による追跡, 複素スペクトルパラメータを入力する neural network による表現, の三段階を扱う。主要な取り組みは合計六項目である。

2.1 Principal chiral model: bare flatness loss と再パラメータ化自由度

current を $J_{\pm}$ とし,

$$L_+ = a(\lambda)J_+, \quad L_- = c(\lambda)J_- \quad (1)$$

という ansatz を用いる. λ に依存する追加の重みを導入せず, flatness residual の二乗を損失関数とする. $a(\lambda)$ と $c(\lambda)$ をともに学習する場合, $a(\lambda)$ を固定する場合, $a(\lambda)$ を penalty で既知関数の近傍に拘束する場合を比較し, 再パラメータ化自由度が最適化に与える影響を調べる.

2.2 Principal chiral model: analytic per- λ reweighting

$a(\lambda) = \lambda$ を固定した場合の勾配強度を解析し,

$$w(\lambda) \propto \left| \lambda - \frac{1}{2} \right|^{-2} \quad (2)$$

という重みを導入する. 目的は, スペクトルパラメータ領域内で不均一な training signal を補償することである.

2.3 Principal chiral model: component-norm normalization と adaptive weighting

解析解を使わずに training signal の不均一性を抑える. flatness residual を構成する各項の norm を用いる normalization と, 学習中に測定した各 λ の loss に基づく adaptive weighting を組み合わせる.

2.4 $S^2 = SU(2)/U(1)$ sigma model: Jacobian の null space から family を同定する計算

Lie algebra current を

$$J_{\pm} = J_{\pm}^{(0)} + J_{\pm}^{(1)} \quad (3)$$

と分解し,

$$L_+ = aJ_+^{(0)} + bJ_+^{(1)}, \quad L_- = cJ_-^{(0)} + dJ_-^{(1)} \quad (4)$$

と置く. flatness residual の Jacobian の nullity から solution set の局所次元を求め, null vectors から変化しない係数と family に沿って変化する係数を識別する. さらに $a = c = 1$ と $bd = 1$ を事前に仮定せずに抽出する.

2.5 $S^2 = SU(2)/U(1)$ sigma model: pseudo-arclength continuation

Jacobian の null space で得た tangent direction を用いて predictor-corrector 型の pseudo-arclength continuation を行い, flatness solution manifold 内の一実次元 path を追跡する. 一複素次元の solution manifold 自体は二実次元であり, continuation path と manifold 全体を区別する必要がある.

2.6 $S^2 = SU(2)/U(1)$ sigma model: 複素スペクトルパラメータを入力とする neural network

$$\mathcal{N} : \lambda \in \mathbb{C} \mapsto (a(\lambda), b(\lambda), c(\lambda), d(\lambda)) \in \mathbb{C}^4 \quad (5)$$

を学習し, flatness solution manifold の有限領域を滑らかな map として表現する. flatness loss に加え, λ に依存しない map への collapse を防ぐ derivative term と, continuation で得た solution points を用いる anchor term を用いる.

3 既発表論文との差分

既発表論文では, principal chiral model について $a(\lambda) = \lambda$ を固定して $c(\lambda)$ を neural network で学習する計算と component-norm normalization がすでに含まれる. また $S^2 = SU(2)/U(1)$ sigma model については, truncated Laurent ansatz によって明示的な λ dependence を学習している. したがって, 単にスペクトルパラメータを学習すること自体は次論文の差分にはならない.

No.	共同研究者ノートの項目	既発表論文との関係	位置づけ
1	bare flatness loss と三種類の $a(\lambda)$ の扱い	bare loss を含む系統比較は未掲載	基準計算
2	analytic per- λ reweighting	勾配不均一性から解析的な重みを導く 比較は未掲載	明確な差分
3	component-norm normalization と adaptive weighting	normalization 自体は既報, adaptive weighting は未掲載	部分的差分
4	S^2 の Jacobian null-space analysis	family dimension と invariant を Jacobian から抽出する手順は未掲載	明確な差分
5	S^2 の pseudo-arclength continuation	solution manifold の continuation は未掲載	明確な差分
6	S^2 の neural-network chart	continuation points を anchor とする chart は未掲載	明確な差分

六項目すべてに未発表の比較または数値結果が含まれる. 新しい方法として数えると五項目に未発表の method element があり, そのうち四項目は既発表論文から明確に切り分けられる.

4 追加検証 1: principal chiral model における $F_{+-} = Q(\lambda)E$

4.1 設定

群値場を $g(x)$ とし, right-invariant current を

$$J_{\pm} := g^{-1} \partial_{\pm} g \quad (6)$$

と定義する. Maurer–Cartan identity は

$$\partial_+ J_- - \partial_- J_+ + [J_+, J_-] = 0 \quad (7)$$

であり, equation of motion は

$$\partial_+ J_- + \partial_- J_+ = 0 \quad (8)$$

である. equation-of-motion residual を

$$E := \partial_+ J_- + \partial_- J_+ \quad (9)$$

と定義する.

標準的な Lax connection

$$L_+(\lambda) = \frac{1}{1-\lambda} J_+, \quad L_-(\lambda) = \frac{1}{1+\lambda} J_- \quad (10)$$

に対して, Lax curvature

$$F_{+-} := \partial_+ L_- - \partial_- L_+ + [L_+, L_-] \quad (11)$$

は, 式 (7) を使うと

$$F_{+-}(\lambda) = Q(\lambda)E, \quad Q(\lambda) = -\frac{\lambda}{1-\lambda^2} \mathbf{1}_{\mathfrak{su}(2)} \quad (12)$$

となる.

学習時には式 (12) を与えない. neural network は $(\operatorname{Re} \lambda, \operatorname{Im} \lambda)$ を入力し, 一般の複素 3×3 matrix を出力する. 各 sample では J_+, J_-, E を独立に生成し, $C = [J_+, J_-]$ として

$$\partial_+ J_- := \frac{E - C}{2}, \quad \partial_- J_+ := \frac{E + C}{2} \quad (13)$$

と置く. これにより Maurer–Cartan identity は満たすが equation of motion は満たさない data を得る. 損失関数は

$$\mathcal{L}_Q = \frac{\langle \|F_{+-} - QE\|^2 \rangle}{\langle \|F_{+-}\|^2 \rangle + 10^{-30}} \quad (14)$$

である.

4.2 五つの独立な初期値に対する結果

random seed 1234, 2026, 2718, 4242, 31415 を用いて, network architecture と学習条件を変えずに五回学習した.

held-out residual は 2.10×10^{-2} から 3.45×10^{-2} , 解析解に対する相対 matrix error は 2.10×10^{-2} から 3.46×10^{-2} の範囲であった. 三つの diagonal entries が同じ関数に近づく構造は全 run で安定している.

$\lambda = 0$ では解析的に $Q(0) = 0$ である. 五回の学習における learned $Q(0)$ の operator norm は平均 1.63×10^{-2} , standard deviation 5.12×10^{-3} であった. したがって有限精度の learned matrix に通常の numerical rank を直接適用すると, 厳密には rank zero の点でも full rank と判定され得る. 今後は operator norm の suppression と, 非零 operator に対する singular-value ratios を分けて診断する.

評価量	平均	standard deviation
$\ F_{+-} - QE\ /\ F_{+-}\ $	2.96×10^{-2}	5.57×10^{-3}
Q の解析解に対する相対 matrix error	2.97×10^{-2}	5.59×10^{-3}
off-diagonal norm fraction	1.25×10^{-2}	6.20×10^{-3}
diagonal-entry relative spread	4.37×10^{-3}	6.80×10^{-4}

表 2 Principal chiral model における五回の独立な学習結果. 解析解は学習 loss には使用していない.




図 1 五回の学習で得た $Q(\lambda)$ の diagonal entries の平均. 帯は run 間の一 standard deviation.

5 追加検証 2 : $S^2 = SU(2)/U(1)$ sigma model における

$$F_{+-} = Q(\lambda)E$$

5.1 座標表示と equation of motion

S^2 の標準座標を (θ, ϕ) とする. light-cone derivatives を $\partial_{\pm}$ とし, 二つの独立な equation-of-motion residual を

$$E_{\theta} := \partial_+ \partial_- \theta - \sin \theta \cos \theta \partial_+ \phi \partial_- \phi, \quad (15)$$

$$E_{\phi} := \sin \theta \partial_+ \partial_- \phi + \cos \theta (\partial_+ \theta \partial_- \phi + \partial_- \theta \partial_+ \phi) \quad (16)$$

と定義する. field equations は $E_{\theta} = E_{\phi} = 0$ である.

symmetric-coset decomposition を

$$J_{\pm} = J_{\pm}^{(0)} + J_{\pm}^{(1)} \quad (17)$$




図2 複素スペクトルパラメータ領域における pointwise Frobenius error の五 run 平均.

とし, 標準的な Lax connection を

$$L_+(\lambda) = J_+^{(0)} + \lambda J_+^{(1)}, \quad L_-(\lambda) = J_-^{(0)} + \lambda^{-1} J_-^{(1)} \quad (18)$$

とする. Lie algebra basis (T_1, T_2, T_3) における curvature components は

$$F^1 = (\lambda^{-1} - \lambda)E_\phi, \quad (19)$$

$$F^2 = (\lambda - \lambda^{-1})E_\theta, \quad (20)$$

$$F^3 = 0. \quad (21)$$

したがって residual vector を (E_ϕ, E_θ) の順に並べると,

$$Q(\lambda) = \begin{pmatrix} \lambda^{-1} - \lambda & 0 \\ 0 & \lambda - \lambda^{-1} \\ 0 & 0 \end{pmatrix} \quad (22)$$

である.

5.2 学習 data と neural network

θ は座標極 $\sin \theta = 0$ から離れた領域で sample する. $\partial_\pm \theta$, $\partial_\pm \phi$, E_θ , E_ϕ を独立に生成し, 定義式を逆に解いて mixed second derivatives を決める. これにより equation of motion を満たさない off-shell data を作る.

spectral-parameter domain は

$$0.5 \leq \text{Re } \lambda \leq 1.5, \quad -0.5 \leq \text{Im } \lambda \leq 0.5 \quad (23)$$




図3 $\lambda = 0$ における learned Q の singular values. 解析解では三つともゼロである.

とし, λ^{-1} の pole である $\lambda = 0$ を避ける. 一方 $\lambda = 1$ は domain 内に残す. 式 (22) から $Q(1) = 0$ なので, $\lambda = 1$ は dynamics を encode しない既知の control point になる.

neural network は $(\text{Re } \lambda, \text{Im } \lambda)$ を入力し, 一般の複素 3×2 matrix を出力する. zero third row, 二つの off-diagonal zero entries, および $Q_{11} = -Q_{22}$ という構造は学習器に与えない. 損失関数は principal chiral model と同じ normalized squared residual を用いる.

5.3 一回目の数値結果

random seed 1234 で 4000 training steps を行った結果, held-out data に対して

$$\frac{\|F_{+-} - QE\|}{\|F_{+-}\|} = 1.13 \times 10^{-2} \quad (24)$$

であり, 解析式 (22) に対する相対 matrix error も 1.13×10^{-2} であった. 解析的に zero である entries が担う matrix norm の割合は 8.09×10^{-3} , 関係 $Q_{11} + Q_{22} = 0$ の相対 violation は 4.34×10^{-3} であった.

$\lambda = 0.75$ では解析的な二 singular values はともに 0.58333 であり, learned values は 0.58429 と 0.57548 であった. $\lambda = 1.25$ では解析値 0.45000 に対して learned values は 0.45429 と 0.44527 である. generic な λ では二つの equation-of-motion directions がほぼ同じ強さで回収されている.

一方 $\lambda = 1$ では解析的に二 singular values がともに zero であり, learned values は 1.15×10^{-2} と 4.81×10^{-3} まで抑制された. principal chiral model の特殊点とは異なる模型でも, operator norm の suppression によって dynamics を encode しない spectral point を検出できることが確認できた.




図 4 $\text{Im } \lambda = 0$ における二つの active matrix entries. 解析式 (22) は学習には使用していない.




図 5 $\text{Im } \lambda = 0$ における learned 3×2 matrix の二 singular values. $\lambda = 1$ で同時に zero へ向かう.

6 今後の予定

6.1 共同研究者ノートの再現

6.1.1 Principal chiral model: bare flatness loss と再パラメータ化自由度

6.1.2 Principal chiral model: analytic per- λ reweighting

6.1.3 Principal chiral model: component-norm normalization と adaptive weighting

6.1.4 $S^2 = SU(2)/U(1)$ sigma model: Jacobian null-space analysis

6.1.5 $S^2 = SU(2)/U(1)$ sigma model: pseudo-arclength continuation

6.1.6 $S^2 = SU(2)/U(1)$ sigma model: neural-network chart